

# 机器学习第一次作业

2020年9月

## 1 线性回归扩展

课堂上，老师讲解了如何求 $J(\mathbf{w}) = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2$ 的最优解，其中 $\mathbf{X} \in \mathbb{R}^{n \times d}$ ,  $\mathbf{y} \in \mathbb{R}^n$ ,  $\mathbf{w} \in \mathbb{R}^d$ 。这个问题的最优解可以通过求解最优性方程 $\nabla_{\mathbf{w}} J(\mathbf{w}) = \mathbf{0}$ 得到。

(1) 该问题还可以通过牛顿法求解。请写出 $J(\mathbf{w})$ 对 $\mathbf{w}$ 的海森矩阵 $H$ 的表达式，并证明 $\mathbf{w} - H^{-1} \nabla_{\mathbf{w}} J(\mathbf{w})$ 就是最优解。

(2) 在课堂上，我们仅考虑了目标变量 $y$ 是标量值的情况。下面我们进行拓展，拓展到多元最小二乘法的求解。给定一个数据集 $\{(x^{(i)}, y^{(i)})\}_{i=1}^n$ ，其中， $x^{(i)} \in \mathbb{R}^d$ ,  $y^{(i)} \in \mathbb{R}^p$ ,  $y^{(i)}$ 为一个向量，损失函数如下：

$$J(\Theta) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^p \left( \left( \Theta^T x^{(i)} \right)_j - y_j^{(i)} \right)^2.$$

其中 $\Theta \in \mathbb{R}^{d \times p}$ ， $\Theta$ 为所求解参数矩阵。通过求解 $\nabla_{\Theta} J(\Theta) = \mathbf{0}$ 得到 $\Theta$ 的解析解。

## 2 L1正则化与L2正则化比较

给定数据矩阵 $\mathbf{X} \in \mathbb{R}^{n \times d}$ ，其中 $n$ 为样本数， $d$ 为每条数据的维度。 $\mathbf{y} \in \mathbb{R}^n$ 是每条数据的标注。为了简化推导过程，假设 $\mathbf{X}^T \mathbf{X} = nI$ ，且在回归过程中不考虑偏差项。 $\mathbf{X}$ 的第 $i$ 列可以简记为 $\mathbf{X}_{*i}$ 。

(1) 使用L1正则化时，损失函数为 $J_1(\mathbf{w}) = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_1$  ( $\lambda > 0$ )。请将目标函数 $J_1(\mathbf{w})$ 改写成 $J_1(\mathbf{w}) = \|\mathbf{y}\|_2^2 + \sum_{i=1}^d f(\mathbf{X}_{*i}, \mathbf{w}_i)$ 的形式。（即给出 $f$ 的表达式，它的第一个参数是向量，第二个参数是标量。表达式中可以使用 $\mathbf{y}$ ，但不能使用其它列 $\mathbf{X}_{*i}$ ）

(2) 利用上一问的答案，给出 $f(\mathbf{X}_{*i}, \mathbf{w}_i)$ 的最优解 $\mathbf{w}_i^* = 0$ 的充要条件。

(3) 将第一问中的L1正则化换成L2正则化，损失函数为 $J_2(\mathbf{w}) = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_2^2$  ( $\lambda > 0$ )。加入L2正则化后，最优解记为 $\mathbf{w}^\#$ 。仿照前两问的流程，给出 $\mathbf{w}^\#$ 的第 $i$ 个元素为0( $\mathbf{w}_i^\# = 0$ )的充要条件。

(4) 如果一个向量的大部分元素都为0，那么它就是稀疏向量。根据前三问的回答，L1正则化的最优解 $\mathbf{w}^*$ 和L2正则化的最优解 $\mathbf{w}^\#$ ，哪一个更可能是稀疏的？为什么？

### 3 局部加权逻辑斯特回归

在这个问题中，我们研究的是局部加权形式的逻辑斯特回归。给定 $n$ 个样本 $\{(x^{(i)}, y^{(i)})\}_{i=1}^n$ ，其中， $x^{(i)} \in \mathbb{R}^d$ 。我们对每个训练样本给予不同的权重，对下面的损失函数 $\ell(\theta)$ 利用牛顿法进行优化（给出伪代码即可，牛顿法每次步长为1）：

$$\ell(\theta) = \frac{\lambda}{2} \theta^T \theta - \sum_{i=1}^n w^{(i)} \left[ y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

其中 $w^{(i)} = \exp\left(-\frac{\|x - x^{(i)}\|^2}{2\tau^2}\right)$ ， $\theta$ 为模型参数， $h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$ 。